

Basic Concept of Ch.9

9. Statistical learning Theory

9.1 Introduction

9.1.1 Statistical learning theory & no-free-lunch theory

9.1.2 Generative & Discriminative Approach

9.2 Risk minimization & generalization

9.3 Uniform convergence

9.4 Stochastic Optimization & Statistical learning theory

9.5 Algorithmic Stability

① 왜 어떤 ML model은 잘 generalization 되고, 어떤 모델은 overfitting 될까?

② 어떤 조건에서 empirical risk가 작다면, true risk도 작다고 보장할 수 있나?

1. 궁금한 것은: true risk $R(h)$ But 데이터셋 D 를 \rightarrow empirical risk $\hat{R}(h)$ 를 최소화해버려!

근데... $\hat{R}(h)$ 이 작다고 $R(h)$ 이 작은 증거 없어?

그럼 $R(h)$, $\hat{R}(h)$ 관계를 알아보자.

2. Error $R(\hat{h}) - R(f^*) = \underbrace{R(\hat{h}) - R(h_H)}_{\text{estimation error}} + \underbrace{R(h_H) - R(f^*)}_{\text{approximation error}}$ f^* : ideal, h_H : H 중 가장 좋은 h , \hat{h} : ERM 선택된 h

↓
분해해버려!

3 Complexity - trade off
 H 가 단순하면 똑같이 잘 못따라쫓아 (approx. error \uparrow) but 일반화 잘해 (estm. error \downarrow)
 H 가 복잡하면 똑같이 잘 따라쫓아 (approx. error \downarrow) but overfitting 되기도 (estm. error \uparrow)

그럼... bias-variance tradeoff가 필요하네?

근데 ERM 잘하려면 조건이 필요하대!

4 Uniform Convergence $\sup |R(h) - \hat{R}(h)| \leq \epsilon$ empirical risk와 true risk의 차이중 가장 크게 어떤 ϵ 안에 있으면, empirical risk가 작으면 true risk도 작대.

③ 근데 uniform convergence가 안되는 경우는?

5 SGD/SGM 같은 stochastic optimization 알고리즘! 근데 EM?

6 SGD는 왜 잘 작동? \because Algorithmic Stability 때문.

여기서는 어떤 algo가 입력 데이터를 약간 바꿔도 학습결과가 거의 안바뀌면 "stable"

stable algorithm은 generalization 잘해.

그럼 stability가 수치적으로 어떻게 되는데?

$\hookrightarrow E[R(\hat{h}) - \hat{R}(\hat{h})] \leq \epsilon$ 이식 strong convexity, Lipschitz 조건하에

$\epsilon = \frac{2L^2}{\lambda n}$ 으로 stability 가져.

9 Statistical Learning Theory

얼마 많은 data가 있어야 어떤 수준의 예측 정확도를 얻을 수 있는지 수학적으로 분석해보자.

Empirical Risk를 잘 줄이는 모델이 true risk도 잘 줄이나? (항상 참은 아님) → 그럼 언제? or 어떤 조건 있을때?

9.1 Introduction

9.1.1 Statistical Learning Theory & No-Free-Lunch Theorems.

• iid sample $(x_1, y_1), \dots, (x_n, y_n) \in \mathbb{R}^d \times \{0, 1\}$ 을 사용해 binary classification을 학습시켜보자.

→ goal: Risk $R(h) = E[\mathbb{1}\{h(x) \neq y\}]$ 를 최소화하는 classifier h 찾기.

• suppose y is Bernoulli distributed with mean $\mu(x)$ ~~if noise = non-zero, error $\neq 0$.~~

⇒ class. error $R(h)$ 를 최소화하는 classifier는 Bayes. Class. 그런데 (x, y) 결합 분포 몰라 → Bayes 계산 불가.

$$h^*(x) = \mathbb{1}\{\mu(x) > 1/2\} \quad \mu(x) \text{ 몰라}$$

solution) $\hat{R}(h)$ Empirical Risk Minimization을 사용해보자.

$$\hat{R}(h) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}\{h(x_i) \neq y_i\}$$

근데 이걸 최소화하는 함수는 단순히 training data 만 이용하는 overfitting model 일 수도 있다.

= No-Free-Lunch; 반면적으로 좋은 학습 방법도 X. 그럼 어떻게? 1) generative

⇒ discriminative

9.1.2 Generative vs. Discriminative

• Generative: $P(x, y)$ or $P(x|y), P(y)$ 를 직접 모델링 e.g) Gaussian Naives Bayes

• Discriminative: $P(y|x)$ or 결정 함수만 모델링 e.g) Logistic Regression, SVM.

• Risk Analysis: $R(\hat{h}) - R(h^*) = \underbrace{R(\hat{h}) - \inf_h R(h)}_{\text{estimation error}} + \underbrace{\inf_h R(h) - R(h^*)}_{\text{approximation error}}$

estimation error
data가 완벽히 생겼는지

approximation error
함수 class H 가 충분히 넓지 않아 생기는 error

* Statistical Learning Theory에서 Empirical Risk Minimization (ERM)의 일반적인 오류를 분석함. 우리는 $h \in H$ 중에서 training data에 대해

Empirical Risk를 최소화하는 \hat{h} 를 선택함. 궁극적 목표는 True Risk가 작은 모델을 찾는 것

• $R(h)$: true risk (population risk)

: $R(h) = E[\text{loss}(h(x), y)]$ 전체 data 분포에 대한 avg. loss

• $\hat{R}(h)$: empirical risk

$\hat{R}(h) = \frac{1}{n} \sum_{i=1}^n \text{loss}(h(x_i), y_i)$ training data에 대한 avg. loss

• \hat{h} : ERM에서 선택된 가설

$\hat{h} = \argmin \hat{R}(h)$

• h_H : H 에서 true risk를 최소화하는 opt. 가설

$h_H = \argmin R(h)$

• $R(\hat{h})$: 선택된 모델 \hat{h} 의 true risk

• $\hat{R}(\hat{h})$: 선택된 모델 \hat{h} 의 empirical risk

• $R(h_H)$: H 내의 최적 가설 h_H 의 true risk

• $\hat{R}(h_H)$: H 내의 최적 가설 h_H 의 empirical risk

$$R(\hat{h}) - R(h_H) = \underbrace{R(\hat{h}) - \hat{R}(\hat{h})}_{\text{일반화 오류}} + \underbrace{\hat{R}(\hat{h}) - \hat{R}(h_H)}_{\text{emp. risk 최소화}} + \underbrace{\hat{R}(h_H) - R(h_H)}_{\text{일반화 오류}} \leq |R(\hat{h}) - \hat{R}(\hat{h})| + |\hat{R}(h_H) - R(h_H)|$$

generation gap 항상 ≤ 0

($\because \hat{h}$ 는 \hat{R} 를 최소화하는 함수)

$$\rightarrow R(\hat{h}) - R(h_H) \leq |R(\hat{h}) - \hat{R}(\hat{h})| + |\hat{R}(h_H) - R(h_H)|$$

$$\rightarrow |R(\hat{h}) - R(h_H)| \leq \sup_{h \in H} |\hat{R}(h) - R(h)| \quad \because \hat{h} \in H \text{ 이므로 어떤 } h \in H \text{ 에 대해서도 generation gap은 supremum 보다 작다.}$$

9.2 Risk Minimization & Generation

$$R(f) = \underbrace{R(f) - R(f_H)}_{\text{estimation error}} + \underbrace{R(f_H) - R(f^*)}_{\text{approximation error}} + R(f^*)$$

- complex model \Rightarrow approx error \downarrow , estima. error \uparrow
- simple model \Rightarrow approx error \uparrow , estima. error \uparrow

* trade-off 설명

e.g.) Linear Regression $H = \{h_\theta(x) = \theta^T x\}$.

Neural network
더 큰 H .

- Class H : 우리가 모델을 고르는 후보군 집합.

5차 다항식 $H = \{h(x) = a_0 + a_1x + \dots + a_5x^5\}$


\rightarrow 100차 다항식은 1차 함수보다 더 많은 곡선 형태 내포.

= H 만이 진짜 최적함수 f^* 와 가까운 함수가 들어왔을 가능성 높음. \approx approximation 가까워짐 \Rightarrow approx. error \downarrow

\hookrightarrow But, data를 위변조 위험이 커짐 (Overfitting) data가 유한하면 일반화가 안될수도. e.g) 5차식 모델인데 data가 3개뿐이면...

(복잡한 모델은 학습해야 할 parameter 수 \uparrow , 즉 data 1개당 설명해야 할 정보량이 적어져서 noise 민감함)

complexity	class H	Approx. Error	Estimation Error
complex	\downarrow	\uparrow (표현력 부족)	\downarrow
simple	\uparrow	\downarrow	\uparrow (추론이 잘 안된 학습 \uparrow)



9.3 Uniform Convergence

Empirical Risk를 잘 줄이는 모델이 true risk도 잘 줄이나요? (항상 참은 아님) \rightarrow 증명해줄래.

• Definition: < Uniform Convergence >

$$\sup_{h \in H} |\hat{R}(h) - R(h)| \leq \epsilon \quad (\text{with high probability})$$

Class H 의 모든 가설에 대해 $\hat{R}(h)$ 와 $R(h)$ 차이가 ϵ 이하임을 보장.
(empirical risk와 true risk의 차이가 작다는 것을 균일하게 보장)

즉 ERM(Empirical risk Minimization)으로 찾은 \hat{h} 도 일반화를 잘 하는거란 이론적 보장

- \hookrightarrow Prop 1: finite H , generalization 보장
- Theorem 1: Infinite H , covering number를 통해 보장
- Prop 2: Lipschitz loss + covering number 상한값에 bound 제공

Prop 1 + Theorem 1 + Prop 2 } uniform convergence $\checkmark \Rightarrow$ ERM 일반화 보장 \Rightarrow empirical risk 작으면 true risk 작다는 말이
Prop 1, Theorem 1, Prop 2를 만족할수록 성립.

• Prop 1: Finite Hypotheses Class

Suppose H finite, $0 \leq \text{loss}(f(x), y) \leq B$ is bounded,
with probability (at least) $1 - \delta$, for all $h \in H$:

$$R(f) \leq \hat{R}(f) + B \sqrt{\frac{\log(|H|/\delta)}{2n}}$$

$$P\left[\sup_{h \in H} |R(h) - \hat{R}(h)| \geq \varepsilon\right] \leq 2|H|e^{-2n\varepsilon^2}$$

* finite H 이면 Hoeffding's Inequality + union Bound \Rightarrow bound 가능

proof) $P\left[\max_i (R(f_i) - \hat{R}(f_i)) \geq t\right] = P\left[\bigcup_{i=1}^{|H|} (R(f_i) - \hat{R}(f_i)) \geq t\right]$
 $\leq \sum_{i=1}^{|H|} P[R(f_i) - \hat{R}(f_i) \geq t] \leq \sum_{i=1}^{|H|} e^{-\frac{2nt^2}{B^2}} = |H|e^{-\frac{2nt^2}{B^2}}$
 * Hoeffding's Inequality (Theorem 1)

• Theorem 1: Hoeffding's Inequality

Let z_1, \dots, z_n independent random variables taking values in $[a, b]$. Then for $\forall \beta > 0$:

$$P\left[\frac{1}{n} \sum_{i=1}^n (z_i - E[z_i]) \geq \beta\right] \leq e^{-\frac{2n\beta^2}{(b-a)^2}}$$

infinite H 에서는 union bound X 대신 복잡도 측정 도구 필요.

ε -covering number 개념 도입. 즉 H를 몇개의 함수로 근사적으로

덮을 수 있나? $N(H, \varepsilon, n)$

\rightarrow H가 작게 덮이면 (covering number < 1) uniform conv. 성립.

• Prop 2: Lipschitz loss + covering number

suppose loss is Lipschitz, for $\forall z, f, f' \in H$:

$$|\text{loss}(f, z) - \text{loss}(f', z)| \leq L \|f - f'\|$$

Moreover assume loss is bounded $\Leftrightarrow 0 \leq \text{loss}(f, z) \leq B$. Then,

$\sup_f R(f) - \hat{R}(f) \leq \varepsilon$ with probability $1 - N(H, \frac{\varepsilon}{4L}) \cdot e^{-\frac{2n\varepsilon^2}{B^2}}$

Also, $P\left[\sup |R(f) - \hat{R}(f)| \geq \varepsilon\right] \leq N(H, \frac{\varepsilon}{4L}) \cdot e^{-\frac{2n\varepsilon^2}{B^2}}$

* intuitive)

if $N(H, \varepsilon) = 100 \rightarrow \log N = \log(100) \approx 6.9 \Rightarrow$ 필요한 data $n \geq \frac{6.9}{\varepsilon^2}$

if $N(H, \varepsilon) = 10^6 \rightarrow \log N \approx 13.8$

\Rightarrow 동일한 generation bound를 얻으려면 2배 data 필요

Proof). Let $S = \frac{\varepsilon}{4L}$ for H . $f \in H: \exists f' \in S$ s.t.

$$|\text{loss}(f, z) - \text{loss}(f', z)| \leq L \|f - f'\| \leq \frac{\varepsilon}{4}$$

Then, $P\left[\exists f \in H: \frac{1}{n} \sum_{i=1}^n (E[\text{loss}(f, z_i)] - \text{loss}(f, z_i)) \geq \varepsilon\right]$

$$\leq P\left[\exists f \in S: \frac{1}{n} \sum_{i=1}^n (E[\text{loss}(f, z_i)] - \text{loss}(f, z_i)) \geq \frac{\varepsilon}{2}\right]$$

$$\leq N(H, \frac{\varepsilon}{4L}) \cdot e^{-\frac{2n\varepsilon^2}{B^2}} \quad \square$$

9.4 Stochastic Optimization and Statistical Learning Theory

$$\hat{R}(w) = \frac{1}{n} \sum_{i=1}^n \text{loss}(w, z_i) \text{를 최소화!}$$

왜 stochastic optimization 이 중요한가? 많은 ML 문제가 확률 최적화 문제로 표현됨.

$$\min_{w \in \Theta} R(w) := E_{z \sim D} [\text{loss}(w, z)]$$

$R(w)$: True risk (Population Risk) / D : data 분포 / $z = (x, y)$: data point

하지만 우리는 D 를 모르고, 대신 data z_1, \dots, z_n 만 가짐. 그래서 ERM 사용.

Stochastic Gradient Method (SGM)

현실에서 큰 data를 다루기 위해 stochastic gradient method 사용

$$w_{k+1} = \Pi_{\Theta} (w_k - \alpha_k \nabla \text{loss}(w_k, z_k)) \begin{cases} - f_w: \text{model parameterized by } w \in \Theta, \\ - R(f_w): \text{risk} = E[\text{loss}(f_w(x), y)] = R(w) = E[\text{loss}(w, y)] \\ - z_k: \text{mini batch.} \\ - \alpha_k: \text{learning stepsize} \\ - \Pi_{\Theta}: \text{projection onto } \Theta \text{ (optional).} \end{cases}$$

* 성능 분석: SGD는 실제로 얼마나 잘 일반화 할까?

$$\text{Suppose norm of SG: } E[\|\nabla \text{loss}(w_k, z_k)\|_2] \leq B, \text{ where } B = \sup \|\nabla \text{loss}(w, z)\|_2$$

SGD의 iterate avg $\bar{w}_n = \frac{1}{n} \sum w_i$ 에 대해, stepsize를 $\alpha_k = D/B\sqrt{n}$ 로 설정하면:

$$E[R(\bar{w}_n)] - R(w^*) \leq \frac{BD}{\sqrt{n}} \Rightarrow \text{의미: 평균 iterate risk는 } O\left(\frac{1}{\sqrt{n}}\right) \text{ 만큼 } w^* \text{ 보다 나빠지 않음.}$$

여기에 학습률 $\geq 1-\delta$ 로 설정하면:

$$R(\bar{w}_n) - R(w^*) \leq \frac{BD}{\sqrt{n}} (1 + \sqrt{2 \log(1/\delta)})$$

* 결론)

SGD는 널리 쓰이는데 이 이론이 그 일반화 성능을 수학적으로 보장.

→ loss function의 convexity, Lipschitz, boundedness 가정함.

9.5 Algorithmic Stability Stability \approx Robustness

data 하나 바뀐다고 결과가 크게 바뀌지 않는 것. 왜? 일반적으로 stable algorithm은 generalization (일반화) 잘해.

* Flow 9.4) SGM이 왜 generalization 잘하는지 수학적으로 expectation, prob. bound로 설명.

9.5) 어떤 알고리즘이 generalization 잘하냐를 "얼마나 안정적인가?" 라는 관점으로 설명.

Define: Uniform Stability

Consider learning algorithm A . given $Z = \{z_1, \dots, z_n\} \in Z^n$, is ϵ -uniformly stable.

즉, training dataset Z 와 그것과 단 한 sample만 가친 $Z^{(i)}$ 에 대해:

$$\forall z, E[|\text{loss}(A(Z), z) - \text{loss}(A(Z^{(i)}), z)|] \leq \epsilon$$

→ data 하나 바뀌어도 output function은 거의 바뀌지 않음 & 기대값은 알고리즘의 randomness에 대해 취함.

• Proposition 3: Stability \Rightarrow Generalization

let A ϵ -uniformly stable, then generation error of A is bounded by $E[R(A(z)) - \hat{R}(A(z))] \leq \epsilon$

\Rightarrow 즉, 일관한 ϵ 의 기대값이 작다 \approx overfitting 위험이 작다.

• Proposition 4: Regularized ERM is stable

let $A(z)$ minimizing regularized empirical loss of model. 이 알고리즘이 다음 최적화 문제를 풀다면, :

$$\min_w \frac{1}{n} \sum_{i=1}^n \text{loss}(w, z_i) + \frac{\lambda}{2} \|w\|^2 \quad \leadsto \quad \text{이 algorithm 은 } \epsilon = \frac{2L^2}{\lambda n}.$$

* interpretation

• loss가 L -Lipschitz 이고,

• λ -strongly convex 라면

• $n \uparrow \rightarrow$ good stability

• $\lambda \uparrow \rightarrow$ good stability

* Conclusion

1) stability는 data 수 n 과 regularization λ 에 의해 제어됨.

2) SGD 나 Regularized ERM 처럼 실제 사용하는 알고리즘의 일반적인 성능을 stability 관점에서 해석할 수 있음.

3) uniform convergence 없이 generalization 을 설명