

Linear & Ridge Regression → ML에서 갑자기 왜 Regression? \sum Linear Regression, closed-form 해 풀 (계산 비용)

* **Regression** - the Problem of $\left\{ \begin{array}{l} \text{quantity of interest } y : \text{Response / dependent variable} \\ \text{several observed variables } x_1, x_2, \dots, x_n : \text{covariates, features, independent variables} \end{array} \right.$

ex) y : house

x_1 : price

x_2 : room number

x_3 : age of house

\vdots

$x_1, x_2, x_3 \dots$ 조건들을 ****잘 예측**** 해서 조건에 부합하는 best 집을 찾아보자!
(손해 받지 않는 선택을 하겠다!!!)
회선의

1. 문제 세팅 (How the response determined?)

• data: $D = \{(y_1, x_1), (y_2, x_2), \dots, (y_n, x_n)\}$, $x_i \in \mathbb{R}^n$, $y_i \in \mathbb{R}$

• function: $\begin{cases} y_i = \langle x_i, \theta^* \rangle + z_i \\ y_i = h^*(x_i) + z_i \end{cases}$ $z_i = \text{noise}$, $h^* = \text{true underlying assumption}$

****잘 예측**** 한 함수. 규칙. etc.

• goal: 어떻게 하면 잘 예측 함수 있을까? $\Rightarrow \theta^*, h^*$ 찾기

* 문제 θ^*, h^* 에 어떤 힌트도 없음 \rightarrow suppose: the function h is lies in hypothesis class \mathcal{H} ,
the set of function \mathcal{H} is parameterized by a vector θ .

e.g) Linear function: $\mathcal{H}_{\text{linear}} = \{h_\theta(x) = \langle x, \theta \rangle : \theta \in \mathbb{R}^d\}$

가장 좋은 벡터 θ 에 의해 완전히 결정된다

\rightarrow 의미) 함수 h 는 θ 에 의해 결정된다.

θ 는 수많은 data로 학습, 각 데이터에 대해 잘 or 잘못 예측했는지 비교해서 공통점을 찾아보자!

• Loss function (손실함수)

* how well the prediction $h_\theta(x)$ describes output y .

$\hat{\theta} = \underset{\theta}{\operatorname{argmin}} \sum_{i=1}^n \text{loss}(h_\theta(x_i), y_i)$ \rightarrow loss가 가장 작은 곳을 찾아

1.1 Linear Regression

• Linear Model Assumption

$y_i = \langle x_i, \theta^* \rangle + z_i$, x_i : feature vector, θ^* : (우리가 찾는) parameter, z_i : 노이즈


$$\theta_0 + \Rightarrow y_i = \theta_0 + \langle x_i, \theta^* \rangle + z_i = \begin{bmatrix} \theta_0 \\ \theta \end{bmatrix} + \underbrace{\begin{bmatrix} 1 \\ x_i \end{bmatrix}}_x \underbrace{\begin{bmatrix} \theta_0 \\ \theta \end{bmatrix}}_\theta + \underbrace{z_i}_{z_i} = \langle \tilde{\theta}, \tilde{x}_i \rangle + z_i$$

• loss function 데이터를 잘 설명하는 θ 를 찾자 \rightarrow 그럼 모델이 얼마나 잘 예측하냐? \rightarrow 평가 지표 (metrics)를 만들어보자!

sum of squared errors $\hat{R}(\theta) = \frac{1}{n} \sum_{i=1}^n (\langle x_i, \theta \rangle - y_i)^2$ 해석) 예측값과 실제값 사이의 오차를 제곱해서 더한 값

1) 오차 크면 큰 페널티 2) 미분 가능 (최적화)

$$= \frac{1}{n} \|y - X\theta\|^2$$



• 추가)

• 기하학적 해석: $X\hat{\theta}_{LS}$ 는 y 를 X 의 열공간에 직교 투영

• 추정값의 성질: 1) Unbiased $E[\hat{\theta}_{LS}] = \theta^*$

2) Variance $\propto \sigma_{\min}(X)^{-2}$ 즉, X 의 singular value에 반비례. \rightarrow multicollinearity possible

1.2 Least Squares

$$\hat{R}(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \langle x_i, \theta \rangle)^2 = \frac{1}{n} \|y - X\theta\|_2^2$$

- Suppose) 1) $X \in \mathbb{R}^{n \times d}$ matrix
2) full column rank \rightarrow 열들이 선형독립! \rightarrow

Proposition 1: If X has full rank, $\hat{\theta}_{ls} = (X^T X)^{-1} X^T y$

1.2.1 Convex Optimization based on proof of Prop.1

\rightarrow Prop.1 을 Convex Optimization 관점에서 증명해보자.

왜? 다른 모델 (logistic Reg, ...) 에도 확장가능.

Proposition 2. Optimality Condition (최적성 조건)

function f is convex & differentiable, } x^* is global minimizer
Consider a point x^* obeying $\nabla f(x^*) = 0$

수식) $f(y) \geq f(x^*) + \underbrace{\langle y - x^*, \nabla f(x^*) \rangle}_{=0}$
 $\rightarrow f(y) \geq f(x^*) \quad \square$

• Least Square 에 적용해보자.

- function $f(\theta) = \frac{1}{n} \|X\theta - y\|_2^2$
- $f(\theta)$ is convex, diff-ble
- Gradient) $\nabla \hat{R}(\theta) = \langle X\theta - y, X\theta - y \rangle$
 $= \langle \theta, X^T X \theta \rangle - 2 \langle \theta, X^T y \rangle + \langle y, y \rangle$

• Linear Algebraic Proof (가법학적) $\hat{\theta}_{ls}$ 의 의미

$\rightarrow y$ 를 $X\theta$ 로 가장 가깝게 근사한 Projection (직교 투영)

- $X\theta$ 는 X 의 column vector 위에 존재
- 우리는 y 에 가장 가까운 벡터 $X\hat{\theta}$ 를 찾고싶어

수식)

- $X \in \mathbb{R}^{n \times d}$ has full column rank,
- $U \in \mathbb{R}^{n \times d}$, 직교 열 벡터 column orthogonal
- $\Sigma \in \mathbb{R}^{d \times d}$, 대각행렬 singular value $\sigma_1, \sigma_2, \dots, \sigma_d > 0$
- $V \in \mathbb{R}^{d \times d}$, 정규 직교행렬, orthogonal

$$X = U \Sigma V^T$$

☆

1. Linear Regression 해가 존재하나?

2. 있다면 어떻게 구하는데?

3. 이게 왜 좋은/나쁜 해일까?

$X^T X$ invertible possible (if not) \neq singular matrix
 $=$ 역행렬 없음
 \rightarrow 계산 불가 \rightarrow 해 없음

• Definition 1: What is 볼록 convex?

어떤 미분가능한 함수 f 가 다음 조건을 만족하면 convex 하다고 함.

$$f(y) \geq f(x) + \langle y - x, \nabla f(x) \rangle$$

$$\langle y - x, \nabla f(x) \rangle + f(x)$$

\rightarrow 그래프가 접선보다 위에있는 함수

$$\nabla n \hat{R}(\theta) = 2X^T X \theta - 2X^T y$$

$$\nabla \hat{R}(\hat{\theta}_{ls}) = 0$$


$$\Rightarrow 0 = \cancel{2} X^T X \hat{\theta}_{ls} - \cancel{2} X^T y$$

$$\Rightarrow X^T X \hat{\theta}_{ls} = X^T y$$

$$\Rightarrow \hat{\theta}_{ls} = (X^T X)^{-1} X^T y \quad \square$$

*그림 결론?

"gradient = 0" 인 경우 \Rightarrow 해! 라인 재형가능.



$$\hat{\theta}_{ls} = (X^T X)^{-1} X^T y$$

$$U^T U = I$$

$$\bullet X^T X = (U \Sigma V^T)^T (U \Sigma V^T) = (V \Sigma^T U^T) (U \Sigma V^T)$$

$$= V \Sigma^T \Sigma V^T = V \Sigma^2 V^T$$

$$\Rightarrow (X^T X)^{-1} = (V \Sigma^2 V^T)^{-1} = V \Sigma^{-2} V^T$$

$$V^{-1} = V^T$$

$$\bullet X^T y = (U \Sigma V^T)^T y = V \Sigma^T U^T y$$

$$\Rightarrow \hat{\theta}_{ls} = V \Sigma^{-2} V^T \cdot V \Sigma^T U^T y = V \Sigma^{-1} U^T y$$

$$\bullet X \hat{\theta}_{ls} = U \Sigma V^T \cdot V \Sigma^{-1} U^T y = U U^T y$$

$X \hat{\theta}_{ls} = U U^T y$ 의 의미) $U U^T$ 는 X 의 column space 에 대한 projection matrix

• SVD (특이값 분해)

$$X = U \Sigma V^T$$

Σ : 스케일
 U : 왼쪽 특이벡터
 V : 오른쪽 특이벡터
 입력공간을 회전해서 크기 조정해서 출력공간으로 회전하자.

1) V^T : orthogonal matrix \rightarrow 회전

$$V^T = V^{-1}$$

역행렬이 전치행렬

역할: 입력공간을 new basis v_1, v_2, \dots, v_d 로 회전.

2) Σ : diagonal matrix \rightarrow 스케일

$$\begin{bmatrix} \sigma_1 & & & 0 \\ & \sigma_2 & & \\ & & \sigma_3 & \\ 0 & & & \ddots \\ & & & & \sigma_n \end{bmatrix}$$

• $\sigma_i > 0$: 스케일 크기

• 역할: 회전된 입력을 각 방향으로 늘리거나 줄이기.

ex) x 방향 2배, y 방향 0.5배..

$$\begin{bmatrix} x' \\ y' \\ z' \end{bmatrix} = \begin{bmatrix} 2 & & \\ & 0.5 & \\ & & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix}$$

3) U : 출력 공간의 회전

• $U \in \mathbb{R}^{n \times d}$, u_1, u_2, \dots, u_d orthogonal

• $UU^T = I$: u_1, u_2, \dots, u_d 서로 직교


• 역할: 스케일링된 벡터를 출력 공간에서 새 방향으로 회전

ex) $U^T U = \begin{bmatrix} u_1^T \\ u_2^T \\ u_3^T \end{bmatrix} \begin{bmatrix} u_1 & u_2 & u_3 \end{bmatrix} = \begin{bmatrix} u_1^T u_1 & u_1^T u_2 & u_1^T u_3 \\ u_2^T u_1 & u_2^T u_2 & u_2^T u_3 \\ u_3^T u_1 & u_3^T u_2 & u_3^T u_3 \end{bmatrix}$

각 열벡터 서로 직교 \Rightarrow $u_1 \perp u_2, u_2 \perp u_3, u_3 \perp u_1$

$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = I$

ex)



1.3 Analysis of LS estimate & Co-linearity

그럼 우리가 지금까지 구한 해 $\hat{\theta}_{LS}$ 는 항상 좋은가?

\rightarrow 아닐 수도 있음.

\because 현상) features 상관관계 $\uparrow \Rightarrow$ co-linearity 문제

$\Rightarrow \hat{\theta}_{LS}$ 의 Variance (분산) \uparrow , overfitting 발생

어떻게 해결?

\rightarrow Ridge Regression.

Ridge Regression

(idea) LR에서 $\hat{\theta}_{LS}$ 가 과하게 변하거나, 과하게 작아지는 문제를 해결하기 위해 해를 좀 더 제약해 안정적인 추정을 해보자

2.1 Ridge Regression Estimate

- $\hat{\theta}_{LS} = \arg\min \|\mathbf{y} - \mathbf{X}\theta\|_2^2$ (기준)
- 아주 큰 $\|\theta\|$ 는 예측을 불안하게 해. $\rightarrow \|\theta\|$ 를 컨트롤 해보자
 $\rightarrow \|\theta\|$ 에 자체 패널티
- 여전히 convex, diff-able $\Rightarrow \exists$ closed-form 해.

$$\hat{\theta}_{ridge} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$

SVD 기반 해석) shrinkage 관점.

• \mathbf{X} 를 SVD, $\mathbf{X} = \mathbf{U}\Sigma\mathbf{V}^T$

$$\mathbf{X}\hat{\theta}_{ridge} = \sum_{i=1}^d \frac{\sigma_i^2}{\sigma_i^2 + \lambda} \langle \mathbf{y}, \mathbf{u}_i \rangle \mathbf{u}_i$$

shrink factor $\in (0, 1)$

\rightarrow 해석) 각 방향 \mathbf{u}_i 에 대해 shrink factor 를 곱한다.

즉, data 가 약한 방향 (작은 σ_i) 에서는 bias 를 많이 줄인다

\rightarrow 노이즈에 덜 민감 (더 정확하게)

$$\hat{\theta}_{ridge} = \arg\min_{\theta} \underbrace{\|\mathbf{y} - \mathbf{X}\theta\|_2^2}_{\text{fitting error}} + \underbrace{\lambda \|\theta\|_2^2}_{\text{regularization penalty}}$$

$\lambda > 0$: reg. parameter
 \uparrow (크면 더 강한 제약)

$$\begin{aligned} \mathbf{X}\hat{\theta}_{ridge} &= \mathbf{X}(\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y} \\ &= \mathbf{U}\Sigma\mathbf{V}^T (\mathbf{V}\Sigma^T \mathbf{U}^T \mathbf{U}\Sigma\mathbf{V}^T + \lambda \mathbf{V}\mathbf{V}^T)^{-1} \mathbf{V}\Sigma\mathbf{U}^T \mathbf{y} \\ &= \mathbf{U}\Sigma\mathbf{V}^T (\mathbf{V}(\Sigma^2 + \lambda \mathbf{I})\mathbf{V}^T)^{-1} \mathbf{V}\Sigma\mathbf{U}^T \mathbf{y} \\ &= \mathbf{U}\Sigma\mathbf{V}^T \mathbf{V}(\Sigma^2 + \lambda \mathbf{I})^{-1} \mathbf{V}^T \mathbf{V}\Sigma\mathbf{U}^T \mathbf{y} \\ &= \mathbf{U}\Sigma(\Sigma^2 + \lambda \mathbf{I})^{-1} \Sigma\mathbf{U}^T \mathbf{y} \end{aligned}$$

diagonal matrix with $\sigma_i^2 + \lambda$

$$\Rightarrow (\Sigma^2 + \lambda \mathbf{I})^{-1} = \text{diagonal matrix with } \frac{1}{\sigma_i^2 + \lambda}$$

• Σ = diagonal matrix with σ_i

$$\Rightarrow \Sigma(\Sigma^2 + \lambda \mathbf{I})^{-1} \Sigma = \text{diag}\left(\frac{\sigma_1^2}{\sigma_1^2 + \lambda}, \dots, \frac{\sigma_d^2}{\sigma_d^2 + \lambda}\right)$$

$$\Rightarrow \mathbf{U}\mathbf{U}^T \mathbf{y} = \sum \mathbf{u}_i \langle \mathbf{u}_i, \mathbf{y} \rangle = \sum \langle \mathbf{y}, \mathbf{u}_i \rangle \mathbf{u}_i$$

• $\lambda = 0$: 일반 LS (Bias 0, Var \uparrow)

최적 λ 선택방법 • $\lambda \rightarrow \infty$: $\hat{\theta}_{ridge} \rightarrow 0$ (극단적 단원화)

• 보통 cross-validation 사용

2.2 Bias - Variance - Trade off

• Ridge Reg. 추정값에 bias 를 일부 도입 \rightarrow Variance 줄임.

factor	Least Squares	Ridge Regression
Bias	low (0)	high
Variance	大	小
예측 오차	overfitting possible	control with λ

3.3 Bias-Trade-off Ridge Regression 이 때 일반화 성능이 좋은지 수학적으로 알아보자.
 예측 실수를 Bias² + Variance + Noise 로 분해해서 어떻게 Variance를 줄여주는지 분석해보자

• 문제 설정 - Prediction Risk of $\hat{\theta}$

→ 새로운 샘플 $x \in \mathbb{R}^d$ 에 대해 예측할때 (예측 리스크)
 • Model: $y = h(x) + z, z \sim \mathcal{N}(0, \sigma^2)$
 • Dataset: $\mathcal{D} = \{(y_1, x_1), \dots (y_n, x_n)\}$
 • 예측값: $\hat{y} = \hat{h}(x) = \langle \hat{x}, \hat{\theta}_{ridge} \rangle$
 • 실제값: $y = \langle x, \theta^* \rangle + z, z \sim \mathcal{N}(0, \sigma^2)$

Prediction Risk $R(\hat{h}) = E_{x,y} [(\hat{h}(x) - y)^2]$
 + Dataset random (학습)
 $\Rightarrow E_{\mathcal{D}} [R(\hat{h}_{\mathcal{D}})] = E_{x,y,\mathcal{D}} [(\hat{h}_{\mathcal{D}}(x) - y)^2]$

• Goal: $E_{x,y,\mathcal{D}}$ 를 Bias, Variance, Noise 로 분해.

• 수식)

$$E_{\mathcal{D}} [R(\hat{h}_{\mathcal{D}})] = E_{x,y,\mathcal{D}} [(\hat{h}_{\mathcal{D}}(x) - y)^2] = E_{\mathcal{D}} [(\hat{h}_{\mathcal{D}}(x) - h(x) - z)^2]$$

$$= E_{\mathcal{D}} [(\hat{h}_{\mathcal{D}}(x) - h(x))^2] + 2E[(\hat{h}_{\mathcal{D}}(x) - h(x))z] + E[z^2]$$

$$= E_{\mathcal{D}} [(\hat{h}_{\mathcal{D}}(x) - h(x))^2] + E[z^2] \quad \text{z has zero mean.}$$

$$E_{\mathcal{D}} [(\hat{h}_{\mathcal{D}}(x) - h(x))^2] = E_{\mathcal{D}} [(\hat{h}_{\mathcal{D}}(x) - E[\hat{h}_{\mathcal{D}}(x)] + E[\hat{h}_{\mathcal{D}}(x)] - h(x))^2]$$

$$= E_{\mathcal{D}} [(\hat{h}_{\mathcal{D}}(x) - E[\hat{h}_{\mathcal{D}}(x)])^2] - 2(E_{\mathcal{D}}[\hat{h}_{\mathcal{D}}(x)] - E[h(x)])(E[\hat{h}_{\mathcal{D}}(x)] - h(x)) + E[(E[\hat{h}_{\mathcal{D}}(x)] - h(x))^2]$$

$$= E_{\mathcal{D}} [(\hat{h}_{\mathcal{D}}(x) - E[\hat{h}_{\mathcal{D}}(x)])^2] + E[(E[\hat{h}_{\mathcal{D}}(x)] - h(x))^2]$$

= 0, ∵ 기대값 ≈ 평균

Thus we have,

$$E_{\mathcal{D}} [R(\hat{h})] = E_{\mathcal{D}} [(\hat{h}_{\mathcal{D}}(x) - h(x))^2] + E[z^2]$$

$$= \underbrace{E[(E[\hat{h}_{\mathcal{D}}(x)] - h(x))^2]}_{\text{Bias}^2} + \underbrace{E_{\mathcal{D}}[(\hat{h}_{\mathcal{D}}(x) - E[\hat{h}_{\mathcal{D}}(x)])^2]}_{\text{Variance}} + \underbrace{E[z^2]}_{\text{Noise}}$$

= 평균모델과 진짜 함수 h(x) 간의 거리 학습 Dataset 변화에 따른 예측의 흔들림 예측 불확실성

* 직관적 이해 !!!

- Bias가 크다 → 모델이 단순해서 진짜 패턴 못 따라감 (underfitting)
- Variance가 크다 → 데이터셋이 조금 바뀌면 예측이 크게 바뀜 (overfitting)
- Noise는 피할 수 없음

* 왜 중요한가? 모델 선택 & Hyperparameter 튜닝의 근거.
 ~~~~~  
 next chapter